


Anna Marciniak

Podstawy Uczenia Maszynowego lab 5- **Marginesy i kernele** **Raport**




Do wykonania zadania wygenerowałam zbiór danych wzorowany na zbiorze pokazanym w zadaniu.




do wykonania zadania wybrałam następujące współczynniki c :
[$1e-6$, $1e-5$, $1e-4$, $1e-3$, $1e-2$, $1e-1$, 1 , 10 , 100 , 1000]

Losowałam zbiór testowy i treningowy w proporcji 70:30 wyliczyłam trafność i szerokość marginesu tę czynność powtórzyłam 20 razy, uśredniłam i wyliczyłam odchylenie standardowe przedstawione w postaci error barów.

Standardowe SVM

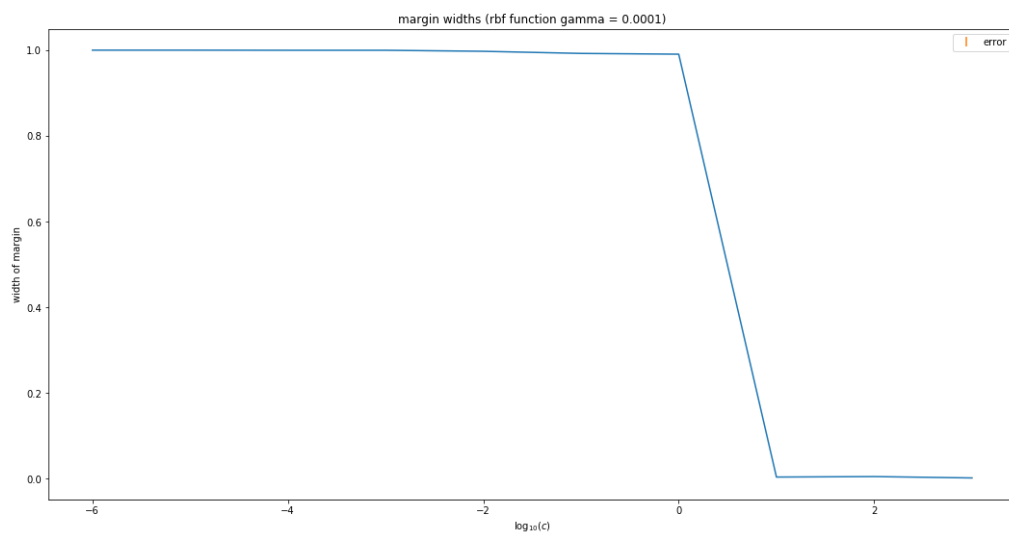
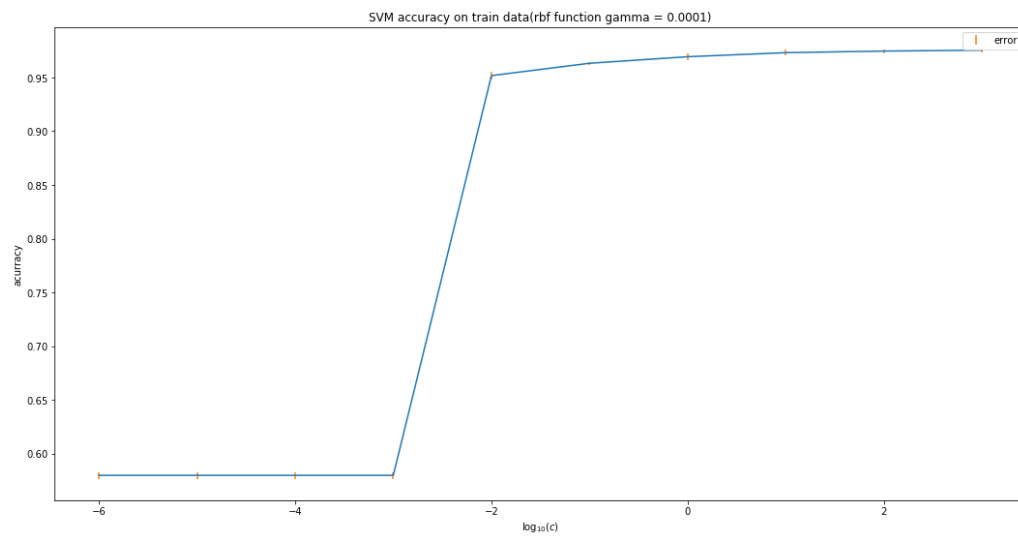
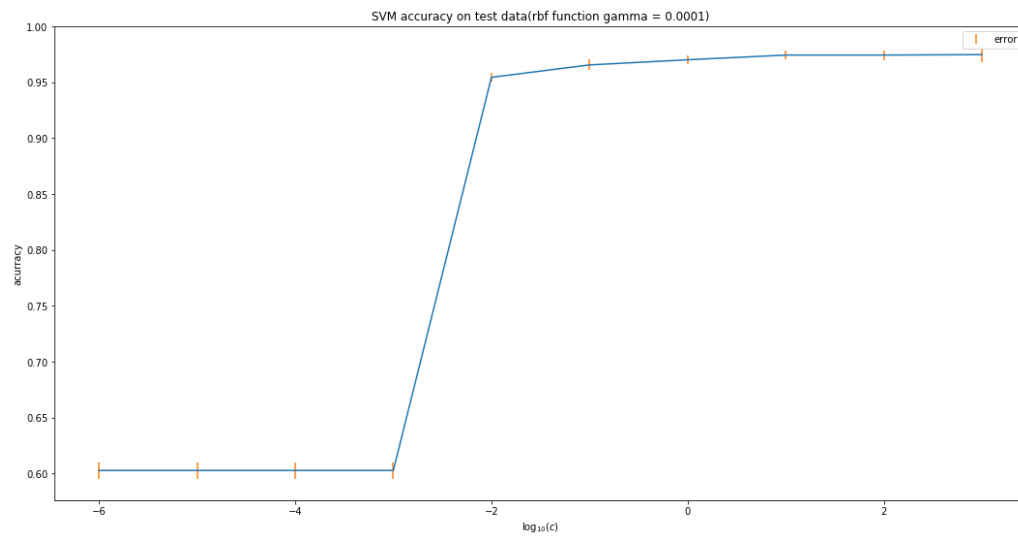


SVM z kernelem wielomianowym, stopnia trzeciego.

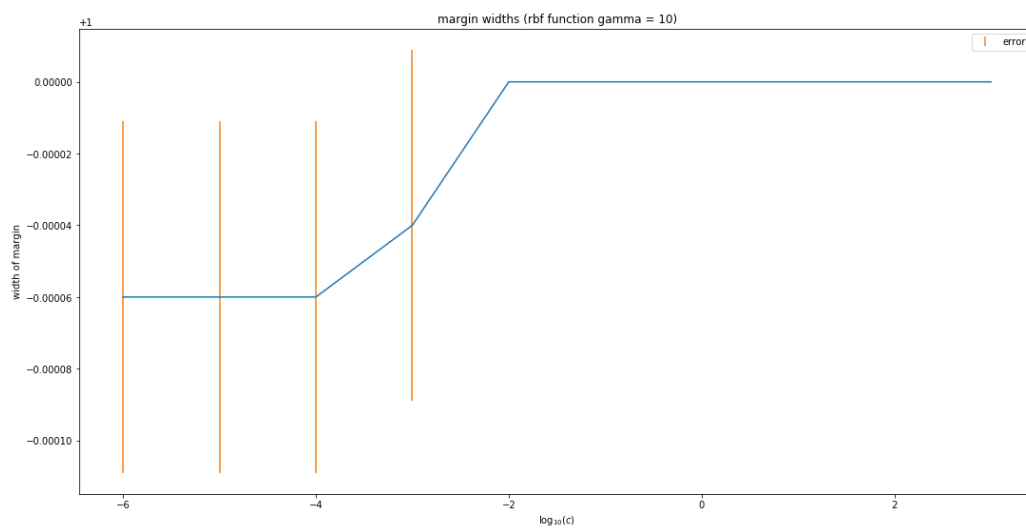
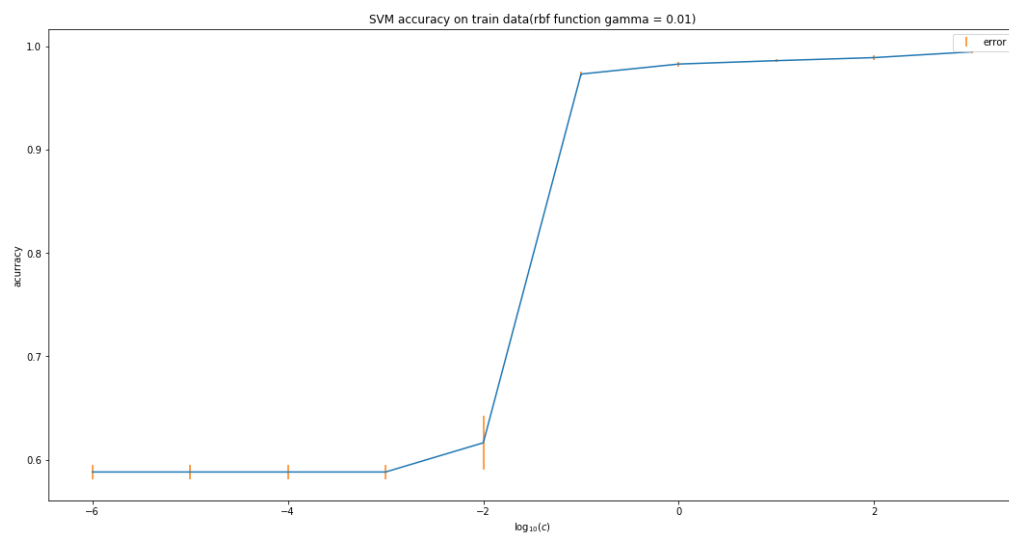



Następne obliczenia wykonywałam tylko 5 razy i uśredniałam wyniki.

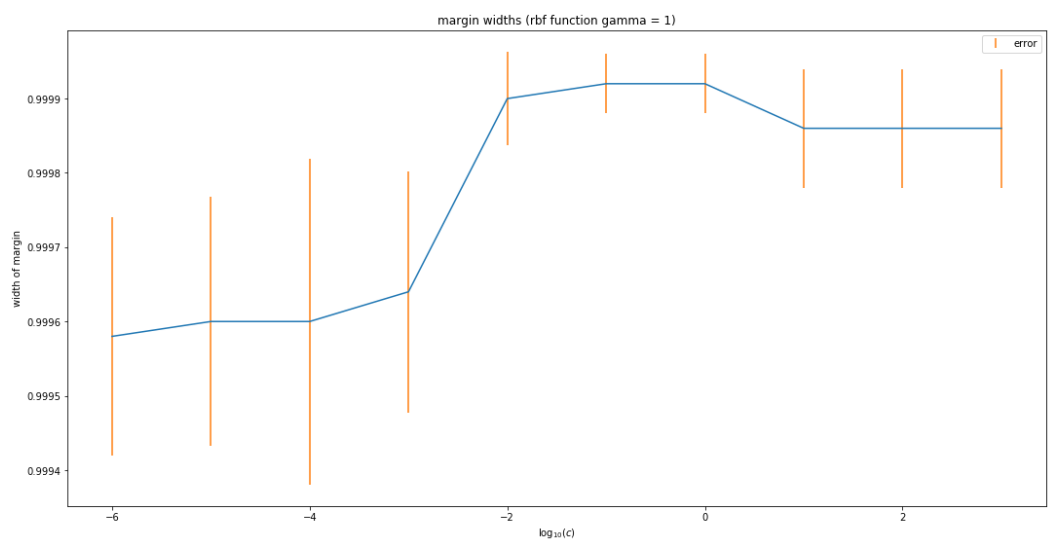

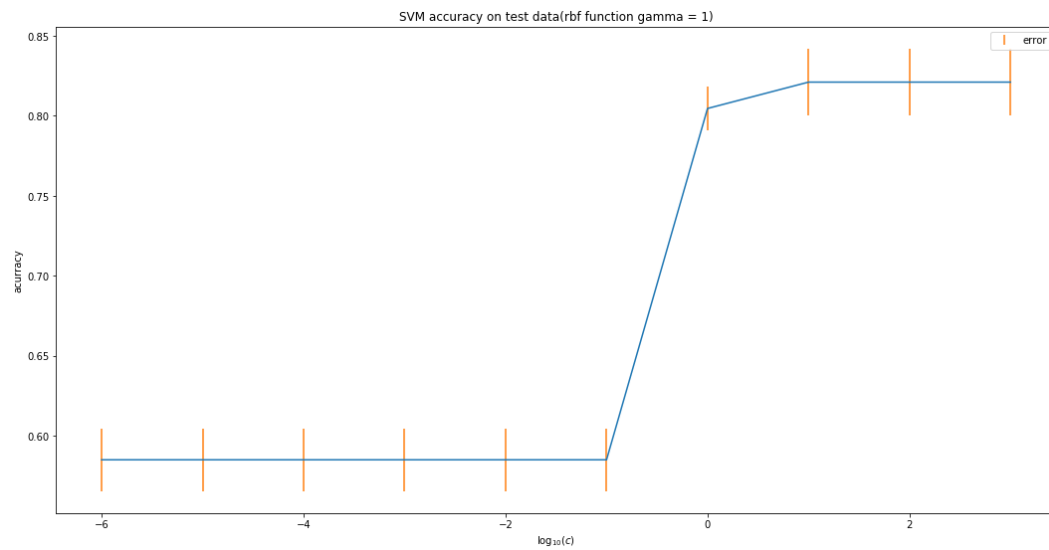
SVM z kernelem rbf dla $\gamma = 0.0001$



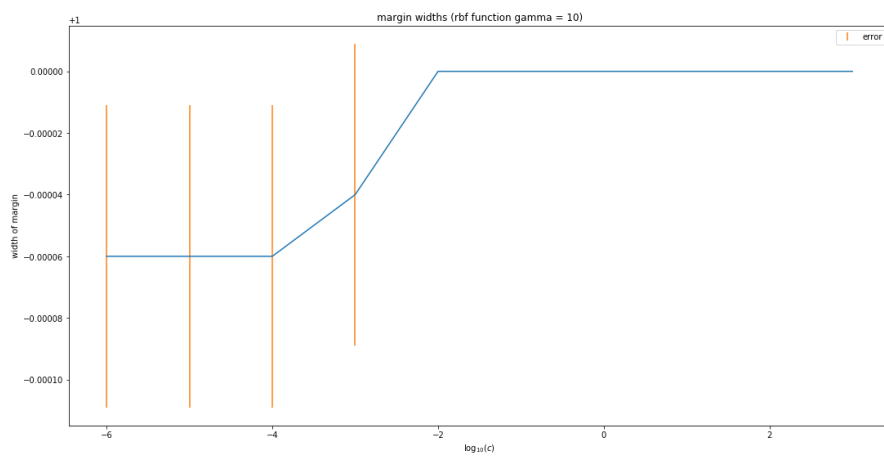

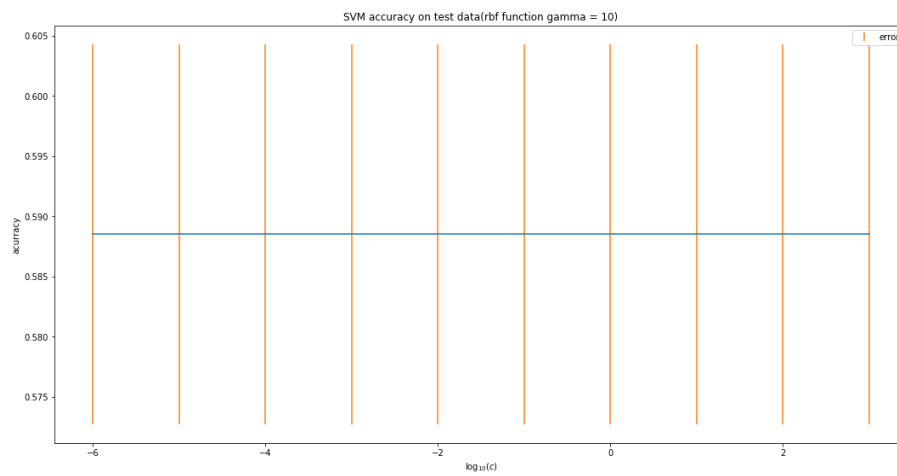
SVM z kernelem rbf dla gamma = 0.01



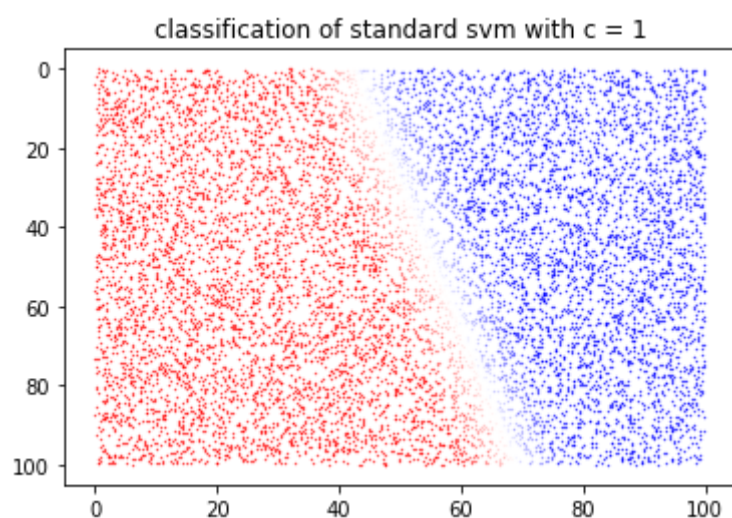


SVM z kernelem rbf dla gamma = 1




SVM z kernelem rbf dla gamma = 10




Wizualizacja klasyfikacji SVM Im bliżej płaszczyzny podziału tym jaśniejsze punkty im dalej tym ostrzejsze. Czerwone punkty, zaklasyfikowane jako klasa 0, niebieskie jako klasa 1.




Klasyfikacja SVM z kernelem wielomianowym stopnia 3ciego $c = 0.0001$




Klasyfikacja SVM z kernelem wielomianowym stopnia 3ciego $c = 0.1$




Klasyfikacja SVM z kernelem wielomianowym stopnia 3ciego $c = 1$




Klasyfikacja SVM z kernelem wielomianowym stopnia 3ciego $c = 10$




classification of rbf kernel svm with $c = 0.0001$, $\gamma = 0.0001$




classification of rbf kernel svm with $c = 0.1$, $\gamma = 0.0001$




classification of rbf kernel svm with $c = 1$, $\gamma = 0.0001$




classification of rbf kernel svm with $c = 10$, $\gamma = 0.0001$




classification of rbf kernel svm with $c = 0.0001$, $\gamma = 0.01$




classification of rbf kernel svm with $c = 0.1$, $\gamma = 0.01$




classification of rbf kernel svm with $c = 1$, $\gamma = 0.01$




classification of rbf kernel svm with $c = 10$, $\gamma = 0.01$




classification of rbf kernel svm with $c = 0.0001$, $\gamma = 1$








classification of rbf kernel svm with $c = 0.1$, $\gamma = 1$



classification of rbf kernel svm with $c = 1$, $\gamma = 1$







Wnioski:

- SVM sobie radzi w klasyfikacji dwóch zbiorów.
- Tradycyjny SVM sobie nie radził z "wyspą" jednej klasy w innej, po prostu podzielił i tyle, widać, że nadaje się tylko do klasyfikacji danych gdzie nie ma szumów.
- SVM z kernelem z funkcji rbf dla $\gamma=0.01$ jest w stanie sobie podzielić klasyfikację z szumami, jak widać zaklasyfikował dobrze "wyspę" punktów klasy 0 wewnątrz klasy 1.
- Dla dużych c przy standardowym SVM i z kernelem wielomianowym margines maleje.
- Dla najmniejszego $c = 0.0001$ przy SVM z kernelem rbf wszystko zostało zaklasyfikowane do klasy 0. Natomiast dla największego $\gamma=10$ granice dla $c = 1$, $c=0.1$, $c=10$ stały się rozległe i tylko kilka punktów zostało zaklasyfikowane do klasy 1